

Resultats dels Models de Predicció

Prophet · XGBoost · LSTM

TFG – Predicció de Generació Renovable i Detecció d'Anomalies
Arnau Ropero Garcia | UAB | Gestió de Ciutats Intel·ligents i Sostenibles | 2025–26

Resum Executiu

Aquest document recull els resultats dels tres models de Machine Learning implementats per predir la generació d'energia solar fotovoltaica i eòlica a Espanya entre abril i maig de 2025. El cas d'estudi central és l'apagada del 28 d'abril de 2025, que va afectar la Península Ibèrica i va provocar una caiguda dràstica en la generació solar en condicions meteorològiques favorables.

Els models s'han entrenat amb dades horàries del període 2023–2024, validats amb gener–març 2025, i avaluats sobre el conjunt de test d'abril–maig 2025. Les mètriques principals usades són MAE (Error Absolut Mitjà) i RMSE (Arrel de l'Error Quadràtic Mitjà), ambdues en megawatts (MW). S'inclou un baseline de persistència (model naïf) com a referència mínima.

L'objectiu no és predir l'apagada, sinó detectar-la *a posteriori*: quan la generació real divergeix significativament de la predicció meteorològica, el model evidencia un factor extern no meteorològic.

1. Mètriques d'Avaluació

1.1 Generació Solar – MAE (MW)

L'error absolut mitjà en MW per a la generació solar fotovoltaica. Valors inferiors indiquen millor rendiment. El MAPE solar no és comparable entre models per la presència de zeros nocturns que fan explotar la mètrica.

Conjunt	Prophet	XGBoost	LSTM	Naïf
Validació	1.346	311	405	1.071
Test	2.060	415	580	1.297

Verd = millor model | **Vermell** = pitjor model. XGBoost domina clarament en solar gràcies als lags autoregressius. Prophet és pitjor que el naïf en validació (1.346 vs 1.071 MW), indicant que no aporta valor sobre la persistència simple.

1.2 Generació Solar – RMSE (MW)

Conjunt	Prophet	XGBoost	LSTM	Naïf
Validació	2.143	588	740	2.025
Test	3.064	730	970	2.332

El RMSE penalitza errors grans. La diferència entre XGBoost (588 MW) i Prophet (2.143 MW) en validació és molt significativa. El salt de validació a test en tots els models reflecteix l'impacte de l'apagada del 28 d'abril.

1.3 Generació Eòlica – MAE (MW)

Conjunt	Prophet	XGBoost	LSTM	Naïf
Validació	1.913	387	375	406
Test	1.711	378	350	443

En eòlica, LSTM (350 MW) supera lleugerament XGBoost (378 MW) al test. Destacar que XGBoost i LSTM a penes milloren el naïf (443 MW vs 350-378 MW), indicant que la persistència ja és un predictor molt competitiu per a l'eòlica.

1.4 Generació Eòlica – RMSE (MW)

Conjunt	Prophet	XGBoost	LSTM	Naïf
Validació	2.456	530	518	576

Test	2.199	519	481	622
------	-------	-----	-----	-----

LSTM obte el millor RMSE eolic al test (481 MW), per sota del naif (622 MW). XGBoost i LSTM son comparables, tots dos molt millors que Prophet.

1.5 Generacio Eolica – MAPE (%) — unica variable on es valid

El MAPE solar no es comparable entre models per la presencia de zeros nocturns (divisio per zero). En canvi, el MAPE eolic es valid porque la generacio eolica mai es propera a zero (minim 190 MW al dataset).

Conjunt	Prophet	XGBoost	LSTM	Naif
Validació	30.76%	5.95%	5.41%	5.98%
Test	42.50%	9.65%	8.68%	10.74%

2. Detecció d'Anomalies – Apagada 28 d'Abril 2025

El llindar d'anomalia es calcula com la mitjana més dues desviacions estandard dels residus absoluts del conjunt de validació ($\text{mean} + 2 \cdot \text{sigma}$). Una hora es marca com a anomalia si el residu absolut supera aquest llindar.

Variable	Prophet	XGBoost	LSTM
Solar – Hores anomalies 28 abr	9 / 24 h	3 / 24 h	9 / 24 h
Solar – Llindar (MW)	4.681	1.615	2.136
Eolica – Hores anomalies 28 abr	1 / 24 h	0 / 24 h	2 / 24 h
Eolica – Llindar (MW)	4.994	1.090	1.010

Interpretació: Prophet i LSTM detecten 9 hores anomalies en solar el 28 d'abril, mentre que XGBoost només en detecta 3. Això es deu al fet que XGBoost utilitza lags autoregressius ($y(t-1)$) que fan que el model s'adapti ràpidament a la caiguda de generació en lloc de mantenir la predicció meteorològica esperada. En eòlica, cap model detecta bé l'apagada, cosa coherent amb la realitat física: la generació eòlica no es va veure tan afectada com la solar.

3. Anàlisi Individual per Model

3.1 Prophet (Facebook/Meta)

Prophet és un model additiu de sèries temporals que descompon les dades en tendència, estacionalitat (anual, setmanal, diària) i festius. No és un model autoregressiu: prediu basant-se exclusivament en patrons temporals i regressors meteorològics externs, sense usar valors passats de la variable target.

Fortaleses: Molt interpretable. Components clarament separables. Ideal per a dades amb estacionalitat forta i festius. Excellent per a detecció d'anomalies perquè manté la predicció meteorològica independent dels valors reals recents.

Debilitats: És el pitjor model en termes de MAE i RMSE. Pitjor que el naïf en solar (no aporta valor predictiu sobre la persistència). No captura bé les discontinuïtats abruptes (zeros nocturns).

Detecció anomalies: El millor (juntament amb LSTM) en solar: 9/24 hores el 28 d'abril. Precisament per no usar lags, manté la predicció alta quan la generació cau per l'apagada.

Conclusió: Útil com a baseline interpretatiu i per a detecció d'anomalies, però inadequat com a model predictiu principal en aquest context.

3.2 XGBoost (Gradient Boosting)

XGBoost és un model de gradient boosting basat en arbres de decisió. Tracta cada hora com una fila independent (no té noció de seqüència), però usa lags de generació (1h, 24h, 168h) com a features explícites per incorporar informació temporal. Escenari: predicció one-step-ahead amb observació contínua (el valor de $t-1$ és conegut en el moment de predir t).

Fortaleses: El millor model en MAE i RMSE solar (311 MW en validació, 5x millor que Prophet). Molt ràpid d'entrenar. Alta interpretabilitat via importància de features (gain).

Debilitats: Dependència dels lags fa que el model s'adapti ràpidament a canvis de generació, reduint la seva capacitat de detecció d'anomalies. En eòlica, a penes millora el naïf (~5% de millora).

Detecció anomalies: El pitjor dels tres en solar (3/24 hores el 28 d'abril). En eòlica, 0 hores detectades. El lag 'segueix' l'apagada en lloc de detectar-la.

Conclusió: Millor model per a predicció de precisió. No adequat per a detecció d'anomalies en escenaris amb lags autoregressius.

3.3 LSTM (Long Short-Term Memory)

El LSTM és una xarxa neuronal recurrent dissenyada per capturar dependències temporals a llarg termini. Rep una finestra de les últimes 24 hores com a entrada i apren automàticament quina informació passada és rellevant, sense necessitar lags manuals. Arquitectura: 1 capa LSTM (64 unitats) + Dropout (0.2) + 2 capes denses.

Fortaleses: Millor model en eolica al test (350 MW MAE, 481 MW RMSE). Bon balanç entre precisió i detecció d'anomalies. Captura patrons temporals complexos sense lags manuals.

Debilitats: Mes complex d'entrenar i ajustar. Pitjor que XGBoost en solar. Necessita normalització correcta (MinMaxScaler fit només en train).

Detecció anomalies: Detecta 9/24 hores anomalies en solar el 28 d'abril (igual que Prophet). Millor que XGBoost perquè la finestra de 24h no 'segueix' la caiguda tan ràpidament com el lag1h de XGBoost.

Conclusió: El millor model en termes de balanç entre precisió i detecció d'anomalies. Recomanat com a model principal si l'objectiu és combinar ambdues capacitats.

4. Conclusions Comparatives

Resum per criteri

Criteri	Millor model	Pitjor model
Precisio solar (MAE)	XGBoost	Prophet
Precisio eolica (MAE)	LSTM	Prophet
Deteccio anomalies solar	Prophet / LSTM (9h)	XGBoost (3h)
Deteccio anomalies eolica	LSTM (2h)	XGBoost (0h)
Interpretabilitat	Prophet	LSTM
Velocitat entrenament	XGBoost	LSTM
Valor sobre naif (solar)	XGBoost	Prophet
Valor sobre naif (eolica)	LSTM	Prophet/XGBoost

Conclusions principals

1. XGBoost es el millor model per a prediccio de precisio en solar (MAE 311 MW en validacio), gràcies als lags autoregressius que li donen avantatge en escenaris one-step-ahead. No obstant, aquesta mateixa característica el fa el pitjor model per a deteccio d'anomalies.
2. LSTM ofereix el millor balanç: competitiu amb XGBoost en precisio eolica i tan bo com Prophet en deteccio d'anomalies solars. Es el model recomanat si l'objectiu es combinar ambdues capacitats.
3. Prophet no supera el baseline de persistencia en solar (MAE 1.346 MW vs naif 1.071 MW), cosa que indica que la seva arquitectura additiva no es la mes adequada per a series amb discontinuitats abruptes. Malgrat això, es el mes interpretable i util per a analisi exploratoria.
4. Cap model detecta be l'apagada en eolica. Això es coherent amb la realitat fisica: la generacio eolica no va caure tan dramaticament com la solar el 28 d'abril, i la seva variabilitat natural absorbeix els residus de l'apagada.
5. L'apagada del 28 d'abril es detecta principalment a traves de la solar: dia assolellat (irradiacio fins a 912 W/m²) pero generacio que cau de ~19.000 a ~5.000 MW. Aquesta divergencia entre condicions meteorologiques favorables i generacio real baixa es la signatura de l'anomalia.